

# Analisis y diseño de algoritmos. Algoritmos voraces (Greedy)

Juan Gutiérrez

September 2019

Son algoritmos que construyen una solución escogiendo de manera local la mejor opción. Son fáciles de diseñar, pero lo difícil es demostrar que el algoritmo devuelve la solución óptima en el largo plazo.

## 1 Intervalos disjuntos (sin pesos)

Sean  $[s_1, f_1], [s_2, f_2], \dots, [s_n, f_n]$  una secuencia de intervalos cerrados en la recta. Dos intervalos son *compatibles* si no se traslapan.

**Problema Max-Intervalos-Disjuntos.** Dada una secuencia de intervalos cerrados en la recta, encontrar un subconjunto de intervalos compatibles dos a dos de tamaño máximo.

Algunos posibles enfoques voraces para resolver el problema:

- Seleccionar un intervalo compatible que empieza antes (menor  $s_i$ )

No funciona si el intervalo es muy grande:




Figure 1: Tomada del libro Kleinberg, Algorithm Design

- Seleccionar un intervalo compatible con menor tamaño (menor  $t_i - s_i$ )

No funciona en algunos casos:




Figure 2: Tomada del libro Kleinberg, Algorithm Design

- Seleccionar un intervalo compatible con menor cantidad de intersecciones  
Es más difícil encontrar un contraejemplo, pero tampoco funciona siempre:




Figure 3: Tomada del libro Kleinberg, Algorithm Design

Una idea que **sí** funciona: tomar el intervalo compatible **con menor valor de su punta final**.

*Recibe:* un conjunto  $\mathcal{I} = \{[s_1, f_1], [s_2, f_2], \dots, [s_n, f_n]\}$  de intervalos

*Devuelve:* un subconjunto de intervalos compatibles dos a dos de tamaño máximo  
MAX-INTERVALOS-DISJ( $\mathcal{I}$ )

```

1:  $A = \emptyset$ 
2: while  $\mathcal{I} \neq \emptyset$ 
3:   Sea  $[s_i, f_i] \in \mathcal{I}$  tal que  $f_i$  es mínimo
4:    $A = A \cup \{[s_i, f_i]\}$ 
5:    $\mathcal{I} = \mathcal{I} \setminus \{[s_k, f_k] : [s_k, f_k] \cap [s_i, f_i] \neq \emptyset\}$ 
6: return  $A$ 
```




Figure 4: Tomada del libro Kleinberg, Algorithm Design

A continuación mostraremos que  $A$  es una solución óptima. Note que el problema puede tener muchas soluciones óptimas. Sea  $X$  una solución óptima cualquiera para el problema, basta mostrar que  $|A| = |X|$ .

Sean  $i_1, i_2, \dots, i_k$  los correspondientes índices de los intervalos en  $A$  en el orden en que fueron adicionados (línea 4).

Sean  $j_1, j_2, \dots, j_m$  los correspondientes índices de los intervalos en  $X$ . Debemos mostrar que  $k = m$ .


**Propiedad 1.1.** *Para todo  $r \leq k$ , se cumple  $f_{i_r} \leq f_{j_r}$*

*Proof.* Por inducción en  $r$ . Si  $r = 1$  entonces la propiedad se cumple debido a la elección hecha en la línea 3 del algoritmo.

Suponga ahora que  $r > 1$ . Por hipótesis de inducción, tenemos que  $f_{i_{r-1}} \leq f_{j_{r-1}}$ .

Como  $X$  tiene intervalos compatibles, se cumple que  $f_{j_{r-1}} < s_{j_r}$ .

Portanto  $[s_{j_r}, f_{j_r}]$  está en el conjunto  $\mathcal{I}$  al momento de elegir el intervalo  $i_r$  en la línea 3 del algoritmo. Debido a la manera que se elige, tenemos que  $f_{i_r} \leq f_{j_r}$ .  $\square$



**Figure 4.3** The inductive step in the proof that the greedy algorithm stays ahead.

Figure 5: Tomada del libro Kleinberg, Algorithm Design

**Teorema 1.1.** *El algoritmo MAX-INTERVALOS-DISJ hace lo pedido*

*Proof.* Suponga por contradicción que el conjunto  $A$  devuelto por el algoritmo no es una solución óptima al problema. Sea  $X$  una solución óptima. Por la Propiedad 1.1 (adoptando la notación necesaria), tenemos (cuando  $r = k$ ) que  $f_{i_k} \leq f_{j_k}$ .

Como  $A$  no es óptima, entonces  $k < m$  y, luego de la ejecución de la línea 5 de la iteración en donde se elige  $i_k$ , el intervalo  $[s_{j_{k+1}}, f_{j_{k+1}}]$  existe en  $\mathcal{I}$ . Portanto el último índice a elegirse en  $A$  no es  $i_k$ , una contradicción.  $\square$

Tiempo de ejecución:  $O(n \lg n)$  (ordenación previa).

El Teorema anterior ha sido demostrado de manera ad-hoc. En la siguiente sección veremos un esquema que permite diseñar y demostrar la correctitud de algoritmos voraces de una manera más estándar.

## 2 Una técnica general para demostraciones

Si queremos demostrar que nuestro algoritmo está correcto basta demostrar dos cosas.

1. *Elección voraz:* debemos demostrar que siempre existe una solución óptima que contiene a la elección voraz
2. *Subestructura óptima:* debemos demostrar que la subsolución dejada es óptima para el subproblema dejado por la elección voraz

Si se demuestran esos dos puntos, demuestro que mi voraz está correcto. Volvamos al problema de intervalos disjuntos para demostrar usando esta técnica.

### 2.1 Demostración para intervalos disjuntos

Recordemos el problema de intervalos disjuntos.

Sean  $[s_1, f_1], [s_2, f_2], \dots, [s_n, f_n]$  una secuencia de intervalos cerrados en la recta. Dos intervalos son *compatibles* si no se traslapan.

**Problema Max-Intervalos-Disjuntos.** Dada una secuencia de intervalos cerrados en la recta, encontrar un subconjunto de intervalos compatibles dos a dos.

*Elección voraz:* elegir el intervalo con menor  $f_i$ .

Planteamos el algoritmo recursivo:

*Recibe:* un conjunto  $\mathcal{I} = \{[s_1, f_1], [s_2, f_2], \dots, [s_n, f_n]\}$  de intervalos, ordenados de manera creciente por punta final

*Devuelve:* un subconjunto de intervalos compatibles dos a dos

MAX-INTERVALOS-DISJ-REC( $\mathcal{I}$ )

- 1: **if**  $\mathcal{I} = \emptyset$
- 2:     **return**  $\emptyset$
- 3:  $\mathcal{I}' = \mathcal{I} \setminus \{[s_i, f_i] : s_i \leq f_1\}$
- 4: **return**  $\{[s_1, f_1]\} \cup \text{MAX-INTERVALOS-DISJ-REC}(\mathcal{I}')$

**Lema 2.1** (Elección voraz). *Existe una solución óptima para el problema que contiene el intervalo  $[s_1, f_1]$ .*

*Proof.* Sea  $X$  una solución óptima para el problema. Si  $X$  contiene a  $[s_1, f_1]$  entonces no tenemos nada que probar.

Suponga entonces que  $[s_1, f_1] \notin X$ . Sea  $[s_j, f_j]$  el intervalo en  $X$  con menor valor de  $f_j$ . Sea  $X' = (X \setminus \{[s_j, f_j]\}) \cup \{[s_1, f_1]\}$ . Mostraremos que  $X'$  es una solución para el problema. Para esto basta mostrar que  $[s_1, f_1]$  es compatible con cualquier intervalo en  $X \setminus \{[s_j, f_j]\}$ .

Sea  $[s_k, f_k]$  un intervalo cualquiera en  $X \setminus \{[s_j, f_j]\}$ . Note que

$$f_1 \leq f_j < s_k,$$

portanto  $[s_1, f_1]$  es compatible con  $[s_k, f_k]$ .

Como  $X'$  es una solución para el problema y  $|X| = |X'|$ , concluimos que  $X'$  es una solución óptima al problema que contiene  $[s_1, f_1]$ .  $\square$

**Lema 2.2** (Subestructura óptima). *Si  $X$  es una solución óptima al problema que contiene a  $[s_1, f_1]$  entonces  $X \setminus \{[s_1, f_1]\}$  es una solución óptima al subproblema dejado por la elección voraz.*

*Proof.* Sea  $\mathcal{I}$  la colección de intervalos del problema original. Sea  $\mathcal{I}'$  la colección de intervalos luego de aplicar la elección voraz, es decir

$$\mathcal{I}' = \{[s_k, f_k] : f_1 < s_k\}.$$

Suponga por contradicción que  $X' = X \setminus \{[s_1, f_1]\}$  no es una solución óptima para  $\mathcal{I}'$ . Entonces existe una solución  $Y'$  para  $\mathcal{I}'$  con  $|Y'| > |X'|$ . Pero en ese caso  $Y = Y' \cup \{[s_1, f_1]\}$  es una solución para  $\mathcal{I}$  con tamaño  $|Y| = |Y'| + 1 > |X'| + 1 = |X|$ , contradicción.  $\square$

Con estos dos lemas a la mano, podemos probar la correctitud del algoritmo.

**Teorema 2.1.** *El algoritmo MAX-INTERVALOS-DISJ-REC hace lo pedido*

*Proof.* Por inducción en  $|I|$ . Si  $|I| = 0$ , entonces  $I = \emptyset$  y el algoritmo retorna  $\emptyset$ , lo cual es correcto. Suponga entonces que  $|I| > 0$ . Como  $|I'| \leq |I|$ , por hipótesis de inducción, en la línea 4, el algoritmo retorna una solución óptima  $X'$  para  $I'$ . Debemos demostrar que  $X = X' \cup \{[s_1, f_1]\}$  es una solución óptima para  $I$ .

Por el Lema 2.1 (Elección Voraz), existe una solución óptima que contiene a  $[s_1, f_1]$ . Sea  $Y = \{[s_1, f_1]\} \cup Y'$  esta solución. Por el Lema 2.2 (Subestructura óptima), se tiene que  $Y'$  es óptima para el subproblema. Luego  $|Y'| = |X'|$  y por lo tanto

$$|Y| = |Y'| + 1 = |X'| + 1 = |X|.$$

Luego, como  $X$  tiene el mismo tamaño que  $Y$ ,  $X$  es una solución óptima para el problema.  $\square$

Si bien es cierto, el Teorema anterior prueba correctamente la correctitud del algoritmo voraz propuesto. De acá en adelante, para los problemas que veamos, podemos asumir que basta demostrar solamente los dos lemas: elección voraz y subestructura óptima.

A continuación, veamos otro ejemplo.

**Ejercicio 2.1.** *Describa un algoritmo eficiente que, dado un conjunto  $\{a_1, a_2, \dots, a_n\}$  de puntos en la recta, tal que  $a_1 \leq a_2 \leq \dots \leq a_n$  determine un conjunto mínimo de intervalos de tamaño 1 que contiene a todos los puntos. Justifique que su algoritmo es correcto usando la propiedades de elección voraz y subestructura óptima.*

Solución: dividiremos nuestra solución en 4 pasos.

1. Elección voraz: Seleccionar  $[a_1, a_1 + 1]$ .

2. Algoritmo recursivo.

*Recibe:* Un conjunto  $A = \{a_1, \dots, a_n\}$  de puntos en la recta real tal que  $a_1 \leq \dots \leq a_n$

*Devuelve:* Un conjunto de intervalos unitarios de tamaño mínimo que cubre  $A$

VORAZ-SEGMENTOS( $A$ )

1: **if**  $A = \emptyset$

2:     **return**  $\emptyset$

3:  $A' = \{a_i \in A : a_i > a_1 + 1\}$

4: **return**  $\{[a_1, a_1 + 1]\} \cup \text{VORAZ-SEGMENTOS}(A')$

3. Prueba de la elección voraz.

**Lema 2.3** (Elección voraz). *Existe una solución óptima que contiene a  $[a_1, a_1 + 1]$ .*

*Proof.* Sea  $X$  una solución óptima. Si  $[a_1, a_1 + 1] \in X$  entonces no hay más que mostrar. Suponga entonces que  $[a_1, a_1 + 1] \notin X$ . Como  $X$  es una solución, existe un intervalo  $[p, p + 1] \in X$  que contiene a  $a_1$ , o sea

$p \leq a_1 \leq p+1$ . Mostraremos que  $X' = X \setminus \{[p, p+1]\} \cup \{[a_1, a_1+1]\}$  es también una solución al problema.

Para esto, debemos probar que todo  $a_i \in A$  está en algún intervalo de  $X'$ . Sea  $a_i \in A$ . Si  $a_i \notin [p, p+1]$  entonces está en algún intervalo de  $X \setminus \{[p, p+1]\}$ . Dicho intervalo también está en  $X'$  y por lo tanto  $a_i$  está cubierto por algún intervalo de  $X'$ . Si  $a_i \in [p, p+1]$  entonces

$$a_1 \leq a_i \leq p+1 \leq a_1+1,$$

y portanto  $a_i \in [a_1, a_1+1]$ . Luego  $X'$  es una solución y como  $|X| = |X'|$ , entonces  $X'$  es una solución óptima.  $\square$

#### 4. Prueba de subestructura óptima

**Lema 2.4** (Subestructura óptima). *Si  $X$  es una solución óptima para  $A$  que contiene a  $\{[a_1, a_1+1]\}$ , entonces  $X \setminus \{[a_1, a_1+1]\}$  es una solución óptima para  $A'$ .*

*Proof.* Suponga por contradicción que  $X' = X \setminus \{[a_1, a_1+1]\}$  no es óptima en  $A'$ . Entonces existe una solución  $Y'$  para  $A'$  tal que  $|Y'| < |X'|$ . Entonces  $Y = Y' \cup \{[a_1, a_1+1]\}$  es una solución para  $A$ . Pero  $|Y| = |Y'| + 1 < |X'| + 1 = |X|$ , una contradicción.  $\square$

### 3 Mochila fraccionaria

Recordemos el problema de la mochila

**Problema Mochila-entera.** Dado un conjunto  $\{1, 2, \dots, n\}$  de items cada uno con un peso natural  $w_i$ , un valor natural  $v_i$  y un número natural  $W$ , encontrar un subconjunto de items cuya suma de valores es la mayor posible, pero menor o igual a  $W$ .

El problema fraccionario permite elegir “fracciones de items” en cada elección.

**Problema Mochila-fraccionaria.** Dado un conjunto  $\{1, 2, \dots, n\}$  de items cada uno con un peso natural  $w_i$ , un valor natural  $v_i$  y un número natural  $W$ , encontrar un vector de racionales entre 0 y 1  $(x_1, x_2, \dots, x_n)$  que maximice  $\sum_{i=1}^n x_i v_i$  sobre la restricción  $\sum_{i=1}^n x_i w_i \leq W$

Ejemplo: suponga que  $W = 50, n = 5, w = [40, 30, 20, 10, 20], v = [840, 600, 400, 100, 300]$ . Entonces  $x = [1, 1/3, 0, 0, 0]$  es una solución viable para el problema, ya que  $1 \cdot 40 + 1/3 \cdot 30 + 0 \cdot 20 + 0 \cdot 10 + 0 \cdot 20 = 50 \leq 50$ .

Elección voraz: escoger siempre los items con mayor ratio valor/peso. Podemos suponer que  $v_1/w_1 \leq v_2/w_2 \leq \dots \leq v_n/w_n$ . Tenemos el siguiente algoritmo.

*Recibe:* Una instancia  $v, w, W$  del problema MOCHILA-FRACCIONARIA

*Devuelve:* Una solución óptima para dicha instancia

MOCHILAFRACCIONARIA-GREEDY( $v, w, W$ )

```

1: for  $j = n$  to 1
2:   if  $w[j] \leq W$ 
3:      $x_j = 1$ 
4:      $W = W - w[j]$ 
5:   else
6:      $x_j = W/w[j]$ 
7:      $W = 0$ 
8: return  $x$ 

```

Note que dicho algoritmo no resuelve el caso de mochila entera, en ese caso se debe aplicar programación dinámica.




Figure 6: Tomada del libro Cormen, Introduction to Algorithms

A continuación demostraremos que nuestro algoritmo está correcto.

**Lema 3.1** (Elección voraz). *Existe una solución óptima  $(x_1, x_2, \dots, x_n)$  al problema tal que  $x_n = \min\{1, W/w_n\}$*

*Proof.* Sea  $\alpha = \min\{1, W/w_n\}$ . Sea  $(y_1, y_2, \dots, y_n)$  una solución óptima al problema **tal que  $y_n$  es máximo**.

Si  $y_n = \alpha$  entonces no hay nada que probar. Suponga entonces que  $y_n \neq \alpha$ .

Como  $y$  es una solución óptima, se cumple que  $y \cdot w \leq W$ . Portanto existe un  $i \in \{1, \dots, n-1\}$  tal que  $y_i > 0$ .

Sea

$$\delta = \min\{y[i], (\alpha - y[n]) \frac{w[n]}{w[i]}\}$$

y

$$\beta = \delta \frac{w[i]}{w[n]}.$$

Note que  $\delta, \beta > 0$ .

Defina  $x$  según



$$x[j] = \begin{cases} y[j] & \text{si } j \notin \{i, n\} \\ y[i] - \delta & \text{si } j = i \\ y[n] + \beta & \text{si } j = n \end{cases}$$

Note que

$$x \cdot w = y \cdot w - \delta w[i] + \beta w[n] = y \cdot w - \delta w[i] + \delta w[i] = y \cdot w.$$

También,

$$\begin{aligned} x \cdot v &= y \cdot v - \delta v[i] + \beta v[n] \\ &= y \cdot v - \delta v[i] + \delta \frac{w[i]}{w[n]} v[n] \\ &= y \cdot v + \delta \left( \frac{w[i]}{w[n]} v[n] - v[i] \right) \\ &= y \cdot v + \delta w[i] \left( \frac{v[n]}{w[n]} - \frac{v[i]}{w[i]} \right) \\ &\geq y \cdot v \end{aligned}$$

Concluimos que  $xv \geq yv$ , y como  $y$  es óptima,  $x$  también es óptima. Pero  $x_n > y_n$ , una contradicción a la elección de  $y$ .

**Lema 3.2** (Subestructura óptima). *Si  $(x_1, x_2, \dots, x_n)$  es una solución óptima al problema con  $x_n = \min\{1, W/w_n\}$ , entonces  $(x_1, x_2, \dots, x_{n-1})$  es una solución óptima al subproblema dejado con  $W = W - x_n w_n$ .*

*Proof.* Suponga por contradicción que no es el caso. Sea  $(y_1, y_2, \dots, y_{n-1})$  una solución óptima al subproblema con peso máximo  $W - x_n w_n$  que escoge los  $n - 1$  primeros items. Entonces  $(y_1, y_2, \dots, y_{n-1}, x_n)$  es una solución viable al problema original con valor mayor que  $x \cdot v$ , contradicción.  $\square$

$\square$

## 4 Código de Huffman (Huffman codes)

Es una codificación de caracteres que permiten compactar archivos de texto. Es decir, transformar un archivo de caracteres en secuencia de bits.

Idea: usar pocos bits para los caracteres más frecuentes, y más bits para los más raros.

	a	b	c	d	e	f
Frequency (in thousands)	45	13	12	16	9	5
Fixed-length codeword	000	001	010	011	100	101
Variable-length codeword	0	101	100	111	1101	1100




Figure 7: Tomada del libro Cormen, Introduction to Algorithms

## Códigos binarios de caracteres

Dado un conjunto  $C$  de caracteres, una *tabla de códigos* para  $C$  es una biyección entre  $C$  y algún conjunto de secuencias de bits. A la secuencia que corresponde a un carácter, le llamamos *código del carácter*.

Una tabla de códigos es *libre de prefijos* (prefix-free) si para cualquier par de caracteres  $x$  e  $y$ , el código de  $x$  no es prefijo del código de  $y$ .

El ejemplo de la figura anterior es libre de prefijos. En dicho ejemplo, la cadena *abacafe* es codificada por 01010100011001101.

## Codificación de archivos

Un *archivo* es una secuencia de caracteres. El conjunto de caracteres es el *alfabeto* del archivo.

El *peso* de un carácter en el archivo es la frecuencia (número de apariciones) de  $c$ , denotado por  $p(c)$ . Note que el número de caracteres del archivo es igual a  $\sum_{c \in C} p(c)$ .

**Problema 4.1.** (*Problema de compresión*) Dado un archivo de caracteres, encontrar una tabla de códigos libre de prefijos que produzca un archivo codificado de tamaño mínimo.

Un árbol de códigos para un conjunto  $C$  de caracteres es un árbol binario en que cada hoja corresponde a un elemento de  $C$  y cada nodo interno tiene exactamente dos hijos.

Sea  $d(c)$  la profundidad del caracter  $c$ . Entonces el número total de bits usados en la codificación es

$$\sum_{c \in C} d(c)p(c).$$

Portanto, el problema anterior es equivalente a encontrar un árbol de códigos cuya suma de pesos por profundidad sea lo menor posible.

## Árboles de Huffman

Sea  $S = \{1, 2, \dots, n\}$ . Un *árbol de Huffman* respecto a  $S$  es cualquier colección  $\Pi$  de subconjuntos de  $S$  que cumple las siguientes propiedades.

1. para cada  $X$  y cada  $Y$  en  $\Pi$ , se tiene que  $X \cap Y = \emptyset$ , o  $X \subseteq Y$  o  $Y \subseteq X$ ,
2.  $S \in \Pi$ ,
3.  $\{\} \notin \Pi$ ,
4. todo elemento no minimal en  $\Pi$ , es la unión de otros dos elementos en  $\Pi$ .

Los elementos de  $\Pi$  son llamados *nodos*. El nodo  $S$  es llamado *raíz*. Los nodos minimales son llamados *hojas*. Todos los otros nodos son llamados *internos*.

Ejemplo: Sea  $S = \{1, 2, 3, 4, 5, 6\}$ , y  $\Pi = \{\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{2, 3\}, \{5, 6\}, \{4, 5, 6\}, \{2, 3, 4, 5, 6\}, \{1, 2, 3, 4, 5, 6\}\}$ .

Si  $X, Y$  y  $X \cup Y$  son nodos del árbol, decimos que  $X$  e  $Y$  son *hijos* de  $X \cup Y$  y que  $X \cup Y$  es el *padre* de  $X$  e  $Y$ .

Un *ancestro* de  $X$  es cualquier nodo  $I$  tal que  $X \subseteq I$ . Si  $I \neq X$  entonces  $I$  es un *ancestro propio*. En el ejemplo,  $\{2, 3, 4, 5, 6\}$  es padre de  $\{4, 5, 6\}$ .

La *profundidad* de un nodo  $X$  es el número de ancestrales propios de  $X$ , será denotado por  $d(X)$ . En el ejemplo,  $d(\{2, 3\}) = 2$ .

Si  $X$  e  $Y$  son hojas, hijas del mismo padre, decimos que son hojas *hermanas*. Note que si  $X$  e  $Y$  son hojas hermanas, entonces  $\Pi - \{X, Y\}$  también es un árbol de Huffman. Decimos que un árbol de Huffman tiene hojas *unitarias*, si cada una de sus hojas tiene solo un elemento.

## Árboles de Huffman de peso mínimo

Una *ponderación* de un conjunto  $S$  es una atribución de pesos numéricos a los elementos de  $S$ . Dada una ponderación  $p_i$  para cada  $i \in S$ , y  $X \subseteq S$ , denotamos por  $p(X)$  a la suma  $\sum_{i \in X} p_i$ . Diremos que  $p(X)$  es el *peso* de  $X$ .

Ejemplo: En el ejemplo anterior, podría asignar  $p(1) = 45$ ,  $p(2) = 13$ ,  $p(3) = 12$ ,  $p(4) = 16$ ,  $p(5) = 9$ ,  $p(6) = 5$ .

El *peso* de un árbol de Huffman  $p(\Pi)$ , denotado por  $p(\Pi)$  es la suma de pesos de los nodos que no son la raíz, osea

$$p(\Pi) = \sum_{X \in \Pi - \{S\}} p(X).$$

En el ejemplo,  $p(\Pi) = p(\{1\}) + p(\{2\}) + p(\{3\}) + p(\{4\}) + p(\{5\}) + p(\{6\}) + p(\{2, 3\}) + p(\{5, 6\}) + p(\{4, 5, 6\}) + p(\{2, 3, 4, 5, 6\}) = 45 + 13 + 12 + 16 + 9 + 5 + 25 + 14 + 30 + 55 = 224$ .

**Ejercicio 4.1.** Probar que  $p(\Pi) = \sum_{X \in \Gamma} p(X)d(X)$ , donde  $\Gamma$  es el conjunto de hojas de  $\Pi$ .

**Problema Min-Peso-Huffman.** Dada una partición  $\Gamma$  y un conjunto  $S$  con una ponderación, encontrar un árbol de Huffman de peso mínimo de entre las que tienen como hojas a  $\Gamma$ .

En el ejemplo,  $S = \{1, 2, 3, 4, 5, 6\}$ ,  $\Gamma = \{\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}\}$ ,  $p(1) = 45$ ,  $p(2) = 13$ ,  $p(3) = 12$ ,  $p(4) = 16$ ,  $p(5) = 9$ ,  $p(6) = 5$ .

## Algoritmo de Huffman

*Recibe:* Un conjunto  $S$ , una ponderación  $p$  de  $S$  y una partición  $\Gamma$  de  $S$

*Devuelve:* Un árbol de Huffman óptimo (con peso mínimo) que tiene a  $\Gamma$  como conjunto de hojas

HUFFMAN( $S, p, \Gamma$ )

- 1: **if**  $|\Gamma| = 1$
- 2:   **return**  $\Gamma$
- 3: Sea  $X$  un elemento en  $\Gamma$  con ponderación mínima
- 4:  $\Gamma = \Gamma - X$
- 5: Sea  $Y$  un elemento en  $\Gamma$  con ponderación mínima
- 6:  $\Gamma = \Gamma - Y$
- 7:  $\Gamma = \Gamma \cup \{X \cup Y\}$
- 8: **return**  $\{X, Y\} \cup \text{HUFFMAN}(S, p, \Gamma)$

Ejemplo: sea  $S = \{1, 2, \dots, 6\}$ ,  $p(1) = 45$ ,  $p(2) = 13$ ,  $p(3) = 12$ ,  $p(4) = 16$ ,  $p(5) = 9$ ,  $p(6) = 5$  y  $\Gamma = \{\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}\}$ .

El algoritmo produce el árbol  $\{\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}, \{6, 5\}, \{6, 5, 4\}, \{2, 3\}, \{2, 3, 4, 5, 6\}, \{1, 2, 3, 4, 5, 6\}\}$ . Su peso es 224.

**Ejercicio 4.2.** Corra el algoritmo de Huffman para  $S = \{1, 2, 3, 4, 5, 6\}$  con hojas unitarias y ponderación  $p(1) = p(2) = p(3) = p(4) = p(5) = p(6)$ . De también un árbol de Huffman no óptimo para esa misma ponderación.

## Correctitud del algoritmo de Huffman

Mostraremos las propiedades de elección voraz y de subestructura óptima.

**Lema 4.1.** (Elección voraz) Sean  $X$  e  $Y$  dos hojas con ponderación mínima. Existe un árbol de Huffman óptimo  $\Pi$  que tiene a  $X$  e  $Y$  como hojas hermanas de profundidad máxima.

*Proof.* Sea  $\Pi$  un árbol de Huffman óptimo con conjunto de hojas  $\Gamma$ . Sean  $V, W$  dos hojas hermanas de profundidad máxima. Luego,  $d(X), d(Y) \leq d(V) = d(W)$ . Suponga sin pérdida de generalidad que  $p(V) \leq p(W)$ . Luego

$$p(X), p(Y) \leq p(V) \leq p(W).$$

Ahora cambiaremos  $X$  y  $V$  de posición en  $\Pi$ , produciendo un nuevo árbol de Huffman  $\Pi'$ . Más precisamente,  $\Pi'$  es definido según:

- para cada ancestro  $I$  de  $X$  que no es ancestro de  $V$ , cambie  $I$  por  $(I - X) \cup V$ ,
- para cada ancestro  $J$  de  $V$  que no es ancestro de  $X$ , cambie  $J$  por  $(J - V) \cup X$ ,

Note que  $\Pi'$  es un árbol de Huffman con conjunto de hojas  $\Gamma$ .  
Note también que

$$\begin{aligned}
 p(\Pi') &= p(\Pi) - \sum_{F \in \Gamma} p(F)d(F) + \sum_{F \in \Gamma'} p(F)d'(F) \\
 &= p(\Pi) - (p(X)d(X) + p(V)d(V)) + (p(X)d'(X) + p(V)d'(V)) \\
 &= p(\Pi) - (p(X)d(X) + p(V)d(V)) + (p(X)d(V) + p(V)d(X)) \\
 &= p(\Pi) + (p(X) - p(V))(d(V) - d(X)) \\
 &\leq p(\Pi)
 \end{aligned}$$

Notamos que el árbol de Huffman  $\Pi'$  es mejor o igual que  $\Pi$  y portanto es también una solución óptima. Repetimos el mismo proceso con  $Y$  y  $W$  obteniendo un árbol  $\Pi''$  que también es óptimo. Más aún,  $\Pi''$  contiene a  $X$  e  $Y$  como hojas hermanas de profundidad máxima.

□

**Lema 4.2.** (*Subestructura óptima*) Sea  $\Pi$  un árbol de Huffman óptimo para  $\Gamma$  que tiene a  $X$  e  $Y$  como hojas hermanas de profundidad máxima. Entonces  $\Pi' = \Pi - \{X, Y\}$  es un árbol de Huffman óptimo para  $\Gamma' = \Gamma - \{X, Y\} \cup \{X \cup Y\}$ .

*Proof.* Suponga por contradicción que existe una solución  $\Phi'$  para  $\Gamma'$  con peso menor a  $\Pi'$ . Entonces  $\Phi = \Phi' \cup \{X, Y\}$  es una solución con menor peso para el problema  $\Gamma$ , contradicción.

□

## Implementación con fila de prioridades

Para implementar el algoritmo de Huffman, podemos hacer uso de fila de prioridades. Recuerde que una fila de prioridades puede hacer la inserción y extracción de un elemento mínimo en  $O(\lg n)$ .

*Recibe:* Un conjunto  $S$ , una ponderación  $p$  de  $S$

*Devuelve:* Un árbol de Huffman óptimo (con peso mínimo) que tiene a los elementos de  $S$  como conjunto de hojas

HUFFMAN-FILAPRIORIDADES( $S, p$ )

```
1:  $n = |S|$ 
2:  $Q = \text{INICIAR-FP}()$ 
3: for  $i = 1$  to  $n$ 
4:    $z.peso = p(i)$ 
5:    $z.left = NIL$ 
6:    $z.rigth = NIL$ 
7:    $\text{INSERT-FP}(Q, z)$ 
8: for  $i = 1$  to  $n - 1$ 
9:    $x = \text{EXTRAERMIN-FP}(Q)$ 
10:   $y = \text{EXTRAERMIN-FP}(Q)$ 
11:   $z.left = x$ 
12:   $z.rigth = y$ 
13:   $z.peso = x.peso + y.peso$ 
14:   $\text{INSERT-FP}(Q, z)$ 
15: return  $\text{EXTRAERMIN-FP}(Q)$ 
```